

به نام خدا

پروژه ۳ درس داده کاوی

عنوان پروژه: سیستم پیش‌بینی قیمت طلا با ترکیب داده‌های تاریخی،
اخبار اقتصادی و مدل‌های یادگیری ماشین و یادگیری عمیق

**Gold price prediction system combining
historical data, economic news, and machine
learning and deep learning models**

تاریخ ارائه گزارش: تیر ۱۴۰۵

توسعه‌دهنده: پریسا پورایوبی/۴۰۱۴۶۳۱۲۶

استاد راهنما: دکتر امید عباس زاده

فهرست مطالب

فصل اول مقدمه

بیان مسئله..... ۳

اهداف پروژه..... ۳

فصل دوم معماری سیستم

دیاگرام معماری..... ۵

دیاگرام فعالیت..... ۶

فصل سوم بخش های مختلف پروژه

بخش های پروژه..... ۷

فصل چهارم نتایج

نتیجه گیری..... ۱۸

Glossary of Terms فصل پنجم

واژه نامه تخصصی پروژه..... ۱۹

۱. مقدمه

۱.۱ بیان مسئله

پیش‌بینی قیمت طلا یکی از چالش‌های مهم در حوزه مالی و اقتصاد است، زیرا قیمت طلا تحت تأثیر مجموعه‌ای از عوامل اقتصادی، سیاسی و روانی بازار قرار دارد. روش‌های سنتی معمولاً تنها بر داده‌های تاریخی قیمت متکی هستند، در حالی که اخبار اقتصادی و سیاسی نیز نقش مهمی در جهت حرکت بازار ایفا می‌کنند.

در این پروژه، یک سیستم ترکیبی طراحی شده است که با استفاده از:

- داده‌های تاریخی بازار
- اخبار مالی واقعی
- تحلیل احساسات مبتنی بر مدل زبان بزرگ (ProsusAI/finbert)
- مدل‌های پیش‌بینی سری زمانی (XGBoost(Extreme Gradient Boosting)

و LSTM

قیمت آینده طلا را پیش‌بینی کرده و توضیحی متنی برای تحلیل ارائه می‌دهد.

۱،۲ اهداف پروژه

هدف اصلی این پروژه، طراحی و پیاده‌سازی یک سیستم ترکیبی هوشمند برای پیش‌بینی قیمت طلا است که با تلفیق داده‌های تاریخی بازار، شاخص‌های اقتصادی کلان و تحلیل معنایی اخبار، بتواند دقت پیش‌بینی را افزایش دهد و خروجی را به‌صورت قابل‌فهم برای کاربران غیرفنی ارائه کند. در این راستا، داده‌های تاریخی قیمت طلا، نقره، شاخص S&P 500، قیمت نفت، شاخص ترس (VIX)، شاخص دلار و بازده اوراق خزانه از سال ۲۰۰۶ تا زمان اجرا جمع‌آوری شده و با استفاده از روش‌های مهندسی ویژگی، شاخص‌های تکنیکال نظیر میانگین‌های متحرک، RSI، MACD و نوارهای بولینگر استخراج شده‌اند. همچنین، با به‌کارگیری مدل زبانی FinBERT، اخبار اقتصادی-سیاسی جمع‌آوری شده از منابع RSS به امتیازات عددی احساسات (بین ۱- تا ۱+) تبدیل شده‌اند.


در نهایت، دو مدل پیش‌بینی XGBoost (برای بازده روزانه) و LSTM (برای قیمت سری‌زمانی) با یکدیگر ترکیب شده و با استفاده از روش وزنی معکوس واریانس، پیش‌بینی نهایی تولید می‌شود. در گام پایانی، یک گزارش متنی طبیعی مبتنی بر خروجی مدل و عوامل مؤثر، با قابلیت بازگشت به قالب پیش‌فرض در صورت عدم دسترسی به سرویس‌های زبانی بزرگ، تولید می‌شود تا تفسیرپذیری سیستم برای تحلیلگران و سرمایه‌گذاران تضمین شود.

۲. معماری سیستم


برای درک بهتر ساختار و جریان پردازش اطلاعات در سیستم طراحی شده، دو دیاگرام در این بخش ارائه شده‌اند. نخست، دیاگرام معماری سیستم، نمای کلی از لایه‌های مختلف پروژه از جمله منابع داده (شامل داده‌های تاریخی و اخبار)، مراحل پردازش (شامل مهندسی ویژگی و تحلیل احساسات)، لایه مدل‌سازی (شامل XGBoost و LSTM)، لایه ادغام و ارزیابی و در نهایت خروجی گزارش‌های متنی را ترسیم می‌کند تا ارتباط بین اجزای مختلف به‌صورت بصری قابل‌درک باشد.

دیاگرام دوم، دیاگرام فعالیت، توالی گام‌های اجرایی پروژه را از مرحله دریافت داده‌های تاریخی و اخبار تا تولید گزارش نهایی پیش‌بینی، به‌صورت گام‌به‌گام نمایش می‌دهد. این دو نمودار به‌طور هم‌زمان، نمای ماکرو و میکرو از فرآیند سیستم ارائه می‌دهند و مسیر تبدیل داده‌های خام به پیش‌بینی‌های قابل‌استفاده و گزارش‌های تفسیرپذیر را شفاف می‌سازند.

شکل ۱- دیاگرام معماری سیستم



شکل ۲- دیگرام فعالیت سیستم



۳. بخش های مختلف پروژه

بخش ۱: راه اندازی و نصب کتابخانه ها (SECTION 1 — Setup)

هدف: ایجاد محیط اجرایی مناسب و نصب تمام کتابخانه های مورد نیاز پروژه.
فناوری های استفاده شده:

- yfinance: دریافت داده های مالی تاریخی از یاهو فاینانس
 - pandas, numpy: پردازش و تحلیل داده های ساختار یافته
 - matplotlib, seaborn: داده ها
 - scikit-learn: پیش پردازش، ارزیابی مدل، و اعتبارسنجی
 - xgboost: پیاده سازی مدل Gradient Boosting
 - tensorflow: ساخت و آموزش شبکه های عصبی LSTM
 - ta: محاسبه شاخص های تحلیل تکنیکال (SMA, EMA, RSI, MACD, Bollinger Bands)
 - transformers: استفاده از مدل های زبانی (FinBERT) برای تحلیل احساسات
 - shap: تفسیر اهمیت ویژگی ها
- دستآورد: ایجاد یک محیط کامل و یکپارچه برای تمام مراحل پروژه.

بخش ۲: دانلود داده ها (SECTION 2 — Data Download)

هدف: جمع آوری داده های تاریخی قیمت طلا و سایر شاخص های اقتصادی مرتبط.
فناوری ها و روش ها:

- yfinance: دریافت داده های روزانه برای نمادهای زیر از سال ۲۰۰۶ تا زمان اجرا:
 - GC=F: قیمت طلا
 - SI=F: قیمت نقره
 - ^GSPC: شاخص S&P 500

- CL=F: قیمت نفت خام
- ^VIX: شاخص ترس
- DX-Y.NYB: شاخص دلار
- ^TNX: بازده اوراق خزانه ۱۰ ساله
- pandas_datareader: دریافت نرخ تورم (CPI) از FRED
- تابع download_with_retry: پیاده‌سازی مکانیزم تلاش مجدد برای مقابله با خطاهای شبکه
- دستآورد: ایجاد یک مجموعه داده جامع شامل ۷ شاخص مالی کلیدی و نرخ تورم، با پوشش زمانی بیش از ۲۰ سال.

بخش ۳: تحلیل داده‌های گم‌شده (SECTION 3 — Missing Data Analysis)

هدف: شناسایی، تحلیل و مدیریت مقادیر گم‌شده در مجموعه داده.

فناوری‌ها و روش‌ها:

- تحلیل مقادیر گم‌شده: محاسبه تعداد و درصد مقادیر مفقود برای هر ستون
- Heatmap: نمایش بصری الگوی داده‌های گم‌شده با استفاده از seaborn.heatmap
- تشخیص تاریخ‌های گم‌شده: مقایسه بازه زمانی کامل با تاریخ‌های موجود
- شناسایی بلوک‌های متوالی گم‌شده: یافتن بازه‌های طولانی از داده‌های مفقود
- مدیریت مقادیر گم‌شده: استفاده از روش‌های bfill (backward fill) و ffill (forward fill)

نتایج تحلیل:

- داده‌ها شامل ۵۱۷۴ رکورد با ۹ ستون است.
- بیشترین مقدار گم‌شده مربوط به US10Y با حدود ۰/۲٪ و کمترین مربوط به Dollar-index با حدود ۰/۰۹٪ است.

- هیچ بلوک طولانی از داده‌های گم‌شده شناسایی نشد.
- پس از پرکردن، تمام مقادیر گم‌شده برطرف شدند.
- دستآورد: اطمینان از کامل بودن داده‌ها برای مراحل بعدی تحلیل و مدل‌سازی.

بخش ۴: تحلیل اکتشافی داده‌ها (SECTION 4 — Exploratory Data Analysis - EDA)

هدف: درک ساختار، توزیع و روابط بین متغیرها و شناسایی الگوهای موجود در داده‌ها.
فناوری‌ها و روش‌ها:

- اطلاعات پایه: نمایش `info()` و آمار توصیفی `describe()`
- روند قیمت طلا: رسم نمودار سری زمانی قیمت طلا در بازه ۲۰۰۶ تا به امروز
- بازده روزانه: محاسبه `pct_change()` و تحلیل توزیع بازده
- نوسان‌پذیری ۳۰ روزه: محاسبه انحراف معیار متحرک بازده روزانه و رسم آن
- ماتریس همبستگی: محاسبه و نمایش همبستگی بین تمام متغیرها با `sns.heatmap`
- روند ویژگی‌های منتخب: رسم همزمان قیمت طلا، نفت، S&P 500، VIX و شاخص دلار
- نمودار جعبه‌ای: شناسایی نقاط پرت با استفاده از `boxplot`

نتایج کلیدی:

- قیمت طلا روند صعودی بلندمدتی داشته و نوسانات شدیدی در دوره‌های بحران (مانند ۲۰۰۸، ۲۰۲۰ و ۲۰۲۴) دارد.
 - بازده روزانه طلا تقریباً نرمال با میانگین نزدیک به صفر است.
 - نوسان‌پذیری ۳۰ روزه در دوره‌های بحران مالی افزایش می‌یابد.
 - همبستگی مثبت قوی بین قیمت طلا و نقره وجود دارد.
 - همبستگی منفی بین قیمت طلا و شاخص دلار مشاهده می‌شود.
 - شاخص VIX (ترس) همبستگی مثبت با نوسان‌پذیری طلا دارد.
- دستآورد: شناخت عمیق از داده‌ها و انتخاب ویژگی‌های مناسب برای مدل‌سازی.

بخش ۵: مهندسی ویژگی‌های پیشرفته (SECTION 5 — Advanced Feature Engineering)

هدف: ایجاد ویژگی‌های جدید و معنادار از داده‌های خام برای بهبود عملکرد مدل.
فناوری‌ها و روش‌ها:

- میانگین‌های متحرک ساده (SMA): محاسبه SMA با پنجره‌های ۷، ۱۴ و ۳۰ روزه
 - میانگین‌های متحرک نمایی (EMA): محاسبه EMA با پنجره‌های ۷ و ۱۴ روزه
 - شاخص قدرت نسبی (RSI): محاسبه RSI ۱۴ روزه با استفاده از `ta.momentum.RSIIndicator`
 - شاخص MACD: محاسبه خط MACD، خط سیگنال و اختلاف آنها
 - نوارهای بولینگر: محاسبه باند بالا، پایین و میانگین با پنجره ۲۰ روزه
 - ویژگی‌های وقفه (Lag Features): ایجاد lag های ۱، ۳ و ۷ روزه از قیمت طلا
 - تغییرات قیمت: محاسبه تفاوت قیمت با وقفه‌های مختلف
 - میانگین و انحراف معیار متحرک: محاسبه آماره‌های متحرک برای پنجره‌های ۷ و ۳۰ روزه
 - نوسان‌پذیری قیمت طلا: محاسبه نوسان‌پذیری ۳۰ روزه از بازده
 - هدف (Target): تعریف متغیر هدف به عنوان قیمت روز بعد
- دستآورد: ایجاد مجموعه‌ای غنی از ویژگی‌ها که اطلاعات تکنیکال و آماری را در بر می‌گیرد و آماده‌سازی داده‌ها برای ورود به مدل

بخش ۶: پردازش اخبار و تحلیل احساسات (SECTION 6 — News Pipeline)

هدف: جمع‌آوری خودکار اخبار اقتصادی و سیاسی مرتبط با طلا و استخراج امتیاز احساسات با استفاده از مدل‌های زبانی بزرگ.

فناوری‌ها و روش‌ها:

- جمع‌آوری اخبار: استفاده از `feedparser` برای دریافت اخبار از RSS گوگل با کلمات کلیدی "gold price", "gold market", "interest rate", "inflation", "federal reserve", "geopolitics economy", "usd dollar strength"
- پیش‌پردازش اخبار: استخراج عنوان، خلاصه، تاریخ و لینک، حذف موارد تکراری
- تحلیل احساسات با FinBERT: استفاده از مدل `ProsusAI/finbert` که برای حوزه مالی تنظیم شده است.

- امتیازدهی: تبدیل برچسب‌های positive، negative و neutral به امتیازات عددی در بازه [-1, 1]
- تجميع روزانه: محاسبه میانگین امتیاز احساسات برای هر روز
- ادغام با داده‌های اصلی: الحاق امتیاز احساسات به دیتاست اصلی
- دستاورد: ایجاد یک ویژگی جدید Sentiment_Score که نشان‌دهنده احساسات بازار در هر روز است و می‌تواند به بهبود پیش‌بینی‌ها کمک کند.

بخش ۷: انتخاب ویژگی، تقسیم داده و مقیاس‌سازی (SECTION 7 — Feature Selection + Train/Test Split + Scaling)

هدف: انتخاب ویژگی‌های مؤثر، تقسیم داده‌ها به مجموعه‌های آموزش و آزمون با رعایت ترتیب زمانی و مقیاس‌سازی ویژگی‌ها.

روش‌ها:

- انتخاب ویژگی: انتخاب ۱۳ ویژگی کلیدی شامل:
 - Silver_Price, SP500, Oil_Price, VIX, Inflation_Rate, Sentiment_Score
 - Gold_Return, Gold_MA_7, Gold_MA_30, Gold_Volatility_30
 - Gold_Lag_1, Gold_Lag_3, Gold_Lag_7
- تقسیم داده: تقسیم ۲۰-۸۰ با رعایت ترتیب زمانی (جلوگیری از نشت داده):
 - split_index = 4112
 - X_train: (4112, 13)
 - X_test: (1028, 13)
- مقیاس‌سازی: استفاده از StandardScaler برای استانداردسازی ویژگی‌ها (میانگین صفر و واریانس یک)
- دستاورد: ایجاد مجموعه‌های آموزش و آزمون معتبر و استاندارد شده که امکان ارزیابی واقع‌بینانه مدل را فراهم می‌کند.

بخش ۸: تنظیم فرآپارامترها با اعتبارسنجی سری زمانی — (SECTION 8 Hyperparameter Tuning + TimeSeriesSplit)

هدف: یافتن بهترین ترکیب فرآپارامترها برای مدل XGBoost با استفاده از اعتبارسنجی سری زمانی.

روش‌ها:

- استفاده از TimeSeriesSplit با ۵ تاییه به جای KFold استاندارد برای جلوگیری از نشت داده‌های آینده

- جستجوی ترکیبی (GridSearchCV) بر روی فرآپارامترها:

- `n_estimators`: ۱۰۰ و ۲۰۰

- `max_depth`: ۳، ۵ و ۷

- `learning_rate`: ۰/۰۱، ۰/۰۵ و ۰/۱

- `subsample`: ۰/۸ و ۱/۰

- معیار ارزیابی: `neg_mean_squared_error`

نتایج بهینه:

- بهترین فرآپارامترها: `{'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 100, 'subsample': 0.8}`

دستآورد: یک مدل XGBoost بهینه‌شده که با روش اعتبارسنجی مناسب سری زمانی تنظیم شده است.

بخش ۹: ارزیابی مدل بر روی مجموعه آزمون (SECTION 9 — Held-out Test Evaluation)

هدف: ارزیابی عملکرد مدل نهایی بر روی داده‌های دیده‌نشده و تحلیل باقیمانده‌ها و اهمیت ویژگی‌ها.

معیارهای ارزیابی مدل XGBoost بر روی داده‌های آزمون:

- MAE (میانگین خطای مطلق): 0.00923885 حدود ۰/۹۲٪ خطا در بازده روزانه

- RMSE (ریشه میانگین مربعات خطا): 0.01278913 حدود ۱/۲۸٪

- R^2 (ضریب تعیین): -۰/۱۰۵۸۶

تفسیر R^2 منفی: این مقدار نشان می‌دهد که مدل XGBoost در پیش‌بینی بازده روزانه، عملکردی بدتر از یک مدل ساده‌ای که همیشه میانگین را پیش‌بینی می‌کند، دارد. این موضوع در پیش‌بینی بازده دارایی‌های مالی طبیعی است، زیرا بازارها کارآمد هستند و پیش‌بینی جهت حرکت کوتاه‌مدت بسیار دشوار است.

بخش ۱۰: تولید توضیحات طبیعی (SECTION 10 — Natural Language Explanation Generator)

هدف: تبدیل پیش‌بینی‌های عددی به توضیحات متنی قابل درک برای کاربران غیرفنی. فناوری‌ها و روش‌ها:

- دریافت آخرین مشاهده: انتخاب آخرین رکورد داده‌ها
- پیش‌بینی: پیش‌بینی بازده روز بعد با مدل بهینه XGBoost
- تفسیر احساسات: طبقه‌بندی امتیاز احساسات به positive، negative یا neutral
- استخراج ویژگی‌های مهم: انتخاب ۳ ویژگی با بیشترین اهمیت
- تولید متن: ساخت یک گزارش متنی شامل:
 - جهت تغییر قیمت (افزایش/کاهش)
 - درصد تغییر مورد انتظار
 - عوامل مؤثر اصلی
 - وضعیت احساسات بازار

بخش‌های ۱۱ تا ۱۳: آماده‌سازی داده‌ها و ساخت مدل (LSTM (SECTIONS 11-13)

هدف: ساخت یک مدل شبکه عصبی LSTM برای پیش‌بینی قیمت طلا بر اساس دنباله‌های زمانی. فناوری‌ها و روش‌ها:

- آماده‌سازی دنباله‌ها: ایجاد پنجره‌های زمانی به طول ۳۰ روز از داده‌های قیمت طلا و امتیاز احساسات
- مقیاس‌سازی: استفاده از MinMaxScaler برای نرمال‌سازی داده‌ها در بازه $[0, 1]$

- معماری: LSTM

- لایه LSTM اول با ۶۴ واحد و `return_sequences=True`

- Dropout 0.2

- لایه LSTM دوم با ۳۲ واحد

- Dropout 0.2

- لایه Dense با ۱۶ واحد و تابع فعال‌سازی `relu`

- لایه خروجی با ۱ واحد

- بهینه‌ساز: Adam

- تابع هزینه: MSE

دست‌آورد: یک مدل LSTM با حدود ۳۰'۰۰۰ پارامتر قابل آموزش که قادر به یادگیری الگوهای سری زمانی است.

بخش ۱۴: آموزش مدل (SECTION 14 — Train LSTM)

هدف: آموزش مدل LSTM بر روی داده‌های سری زمانی.

فناوری‌ها و روش‌ها:

- دوره‌های آموزش: ۲۰ دوره (epochs)

- اندازه بسته: ۳۲ (batch_size)

- اعتبارسنجی: ۱۰٪ از داده‌های آموزش به عنوان اعتبارسنجی

- نظارت: نمایش مقدار `loss` و `validation loss` در هر دوره

نتایج آموزش:

- کاهش تدریجی `loss` از حدود ۰/۰۱۴۶ به حدود ۰/۰۰۰۵۹

- `validation loss` نیز روند کاهشی داشته و به حدود ۰/۰۰۰۳۱ رسیده است.

- نشان‌دهنده عدم `overfitting` قابل توجه.

بخش ۱۵: ارزیابی مدل (LSTM (SECTION 15 — Predict + Evaluate)

هدف: ارزیابی عملکرد مدل LSTM بر روی داده‌های آزمون.

فناوری‌ها و روش‌ها:

- پیش‌بینی: پیش‌بینی قیمت نرمال‌شده بر روی مجموعه آزمون
- معیارهای ارزیابی: MAE، RMSE، R^2
- مقایسه با: XGBoost مقایسه عملکرد دو مدل

نتایج ارزیابی: LSTM

- MAE: ~ 0.2247
- RMSE: ~ 0.303
- R^2 : ~ 0.7904 (نشان‌دهنده برآزش خوب مدل در فضای نرمال‌شده)

تحلیل نتایج:

- R^2 بسیار بالای LSTM نشان می‌دهد که مدل توانسته است الگوی داده‌ها را به خوبی یاد بگیرد، اما این ممکن است به دلیل ماهیت سری زمانی و پیش‌بینی گام‌به‌گام باشد که با استفاده از قیمت‌های گذشته، می‌تواند قیمت آینده را با دقت بالا پیش‌بینی کند.
- LSTM عملکرد بهتری نسبت به XGBoost در پیش‌بینی قیمت دارد، زیرا XGBoost بر روی بازده آموزش دیده و پیش‌بینی بازده کاری دشوارتر است.
- دستاورد: مدل LSTM با دقت بالا قادر به پیش‌بینی قیمت طلا است.

بخش ۱۶: نمودار مقایسه مقادیر واقعی و پیش‌بینی شده (LSTM (SECTION 16 — Plot Actual vs Predicted)

هدف: نمایش بصری عملکرد مدل LSTM در مقابل داده‌های واقعی.

فناوری‌ها و روش‌ها:

- رسم دو سری زمانی: مقادیر واقعی و پیش‌بینی شده بر روی مجموعه آزمون
- استفاده از matplotlib برای ایجاد نمودار

دستآورد: تأیید بصری دقت مدل LSTM در پیش‌بینی قیمت.

بخش ۱۷: تولید توضیحات پیشرفته (SECTION 17 — Advanced Explanation Generator)

هدف: تولید توضیحات طبیعی برای پیش‌بینی قیمت با استفاده از خروجی LSTM.

فناوری‌ها و روش‌ها:

- پیش‌بینی گام بعد: استفاده از آخرین دنباله برای پیش‌بینی قیمت روز بعد
- بازسازی قیمت واقعی: معکوس‌سازی نرمال‌سازی برای تبدیل پیش‌بینی به قیمت واقعی
- تولید متن: ایجاد گزارشی شامل:

- قیمت فعلی

- قیمت پیش‌بینی شده

- جهت تغییر

- عوامل مؤثر (بر اساس مدل و داده‌ها)

دستآورد: یک گزارش طبیعی و قابل فهم برای کاربران نهایی.

بخش ۱۸: پیش‌بینی ۱۰ روز آینده و 10-Day visualisation (SECTION 18 — 10-Day Forecast)

هدف: پیش‌بینی قیمت طلا برای ۱۰ روز آینده با استفاده از مدل LSTM و نمایش نتایج.

فناوری‌ها و روش‌ها:

- پیش‌بینی چندگانه: استفاده از روش پیش‌بینی بازگشتی (recursive forecasting) که در هر گام، پیش‌بینی قبلی به عنوان ورودی به مدل داده می‌شود.
- بازسازی قیمت: تبدیل پیش‌بینی‌های نرمال‌شده به قیمت واقعی
- نمودار: رسم روند ۱۰ روز آینده با نشان‌گذاری قیمت فعلی

- گزارش متنی: خلاصه‌ای از نتایج شامل قیمت فعلی، قیمت پیش‌بینی شده پس از ۱۰ روز و تغییرات مورد انتظار

بخش ۱۹: ترکیب نهایی مدل‌ها (Ensemble) و تولید گزارش هوشمند با قابلیت Fallback

هدف: ترکیب خروجی دو مدل XGBoost و LSTM با استفاده از یک روش وزنی معکوس واریانس (Inverse-Variance Weighting) برای تولید یک پیش‌بینی نهایی با دقت بالاتر، و سپس ارائه این پیش‌بینی در قالب یک گزارش متنی طبیعی و قابل‌فهم برای کاربران، با قابلیت بازگشت به حالت پیش‌فرض در صورت عدم دسترسی به سرویس LLM. فناوری‌ها و روش‌ها:

- ترکیب وزنی (Ensemble Weighting): برای ترکیب دو مدل، از روش Inverse-Variance Weighting استفاده شده است. در این روش، به مدلی که خطای کمتری (RMSE کمتر) در مجموعه آزمون داشته، وزن بیشتری داده می‌شود. این کار باعث می‌شود پیش‌بینی نهایی به مدل دقیق‌تر نزدیک‌تر باشد.

○ RMSE مدل XGBoost بازده روزانه ۰,۰۱۲۷۹

○ RMSE مدل LSTM بازده روزانه ضمنی ۰,۱۱۸۸۸

○ وزن محاسبه‌شده برای XGBoost: ۹۹ درصد

○ وزن محاسبه‌شده برای LSTM: ۱ درصد

- پیش‌بینی نهایی (Ensemble Output):

○ بازده ترکیبی پیش‌بینی‌شده برای روز بعد: ۰,۰۰۵۷۲- (کاهش ۰/۵۷۲ درصدی)

○ قیمت ترکیبی پیش‌بینی‌شده ۳۹۶۲,۸۰ دلار

○ جهت تغییر: کاهش

- تولید گزارش طبیعی (Dual-Mode Report Generation): برای تبدیل اعداد پیش‌بینی به یک توضیح متنی روان و قابل‌درک، یک رویکرد دوحالتی (Dual-Mode) پیاده‌سازی شده است:

۱. حالت اول: تولید گزارش با LLM مدل زبانی بزرگ:

سیستم به یک سرور محلی LM Studio متصل می‌شود و از مدل Qwen3-4b برای تولید یک پاراگراف طبیعی و حرفه‌ای استفاده می‌کند. متن تولید شده، علاوه بر اعداد، شامل تحلیل عوامل

مؤثر (بر اساس اهمیت ویژگی‌ها)، وضعیت احساسات بازار و صراحتاً به محدودیت‌های داده (مانند پوشش کم اخبار) اشاره می‌کند.

۲. حالت دوم: گزارش پیش‌فرض (Fallback / Template) :
در صورت بروز هرگونه خطا در اتصال به سرور LLM (مثلاً خاموش بودن سرویس یا مشکلات شبکه)، سیستم به‌طور خودکار به یک قالب متنی از پیش‌طراحی‌شده (Template) باز می‌گردد. این قالب، همان داده‌های کلیدی (جهت تغییر، درصد، عوامل اصلی، وضعیت احساسات) را به صورت ساختاریافته و منظم نمایش می‌دهد تا خروجی سیستم هرگز بدون توضیح باقی نماند.

۴. نتیجه‌گیری

در این پروژه، سیستم ترکیبی پیش‌بینی قیمت طلا با موفقیت پیاده‌سازی شد. ترکیب مدل‌های XGBoost و LSTM به همراه تحلیل احساسات اخبار، دقت قابل قبولی را در پیش‌بینی فراهم کرد. مدل LSTM در پیش‌بینی قیمت خام عملکرد بهتری نسبت به XGBoost نشان داد، در حالی که Ensemble وزنی تعادل مناسبی بین دقت و پایداری ایجاد کرد. با وجود محدودیت پوشش اخبار تاریخی (حدود ۰/۴٪ روزهای دارای داده)، ادغام ویژگی sentiment تأثیر مثبتی بر توضیح‌پذیری مدل داشت. این رویکرد هیبریدی نشان‌دهنده پتانسیل بالای ترکیب داده‌های کمی و کیفی در پیش‌بینی بازارهای مالی است.

۵. واژه‌نامه تخصصی پروژه (Glossary of Terms)

- **XGBoost**: یک الگوریتم پیشرفته از خانواده Gradient Boosting است که با ساخت متوالی درخت‌های تصمیم و اصلاح خطاهای درخت‌های قبلی، مدلی قوی برای پیش‌بینی ایجاد می‌کند. در این پروژه از این مدل برای پیش‌بینی بازده روزانه قیمت طلا استفاده شده است.
- **LSTM** شبکه حافظه بلندمدت کوتاه‌مدت: نوعی شبکه عصبی بازگشتی (RNN) است که به دلیل ساختار دروازه‌های حافظه‌ای خود، قادر به یادگیری وابستگی‌های طولانی‌مدت در داده‌های سری زمانی می‌باشد. در این پروژه، از این مدل برای پیش‌بینی قیمت لحظه‌ای طلا بر اساس پنجره‌های تاریخی ۳۰ روزه بهره گرفته شده است.
- **FinBERT**: یک مدل زبانی بزرگ (LLM) از خانواده BERT است که به طور ویژه بر روی متون مالی و اقتصادی (اخبار، گزارش‌های تحلیلی و صورت‌های مالی) آموزش دیده است. وظیفه این مدل در پروژه، استخراج امتیاز احساسات (Sentiment Score) از عناوین و خلاصه اخبار اقتصادی است.
- **مهندسی ویژگی (Feature Engineering)**: فرآیند ایجاد، ترکیب و تبدیل داده‌های خام به ویژگی‌های جدید و معنادار است تا مدل بتواند الگوهای پیچیده‌تر را شناسایی کند. در این پروژه شامل محاسبه شاخص‌های تکنیکال نظیر میانگین متحرک (MA)، شاخص قدرت نسبی (RSI)، مکدی (MACD) و همچنین ایجاد وقفه‌های زمانی (Lags) از قیمت‌های گذشته می‌شود.
- **مقیاس‌سازی (Scaling)**: فرآیند تغییر دامنه مقادیر عددی ویژگی‌ها به یک بازه مشخص (مانند [0, 1] یا میانگین صفر و واریانس یک) است. این کار برای جلوگیری از غلبه ویژگی‌های با مقیاس بزرگ‌تر بر مدل‌های مبتنی بر گرادیان (مانند شبکه‌های عصبی) ضروری است. در این پروژه از StandardScaler برای XGBoost و از MinMaxScaler برای LSTM استفاده شده است.
- **وقفه (Lag)**: به مقدار یک متغیر در بازه‌های زمانی گذشته اطلاق می‌شود. برای مثال، **Lag_1** نشان‌دهنده قیمت یک روز قبل است که به مدل کمک می‌کند تا همبستگی‌های سریالی و الگوهای تکراری بازار را درک کند.
- **تقسیم‌بندی سری زمانی (TimeSeriesSplit)**: یک روش اعتبارسنجی متقاطع ویژه داده‌های وابسته به زمان است که در آن ترتیب زمانی داده‌ها کاملاً رعایت می‌شود (داده‌های آموزش همواره قبل از داده‌های آزمون قرار می‌گیرند). این روش از نشت اطلاعات آینده (Data Leakage) جلوگیری می‌کند و ارزیابی را واقع‌بینانه‌تر می‌سازد.
- **شاخص‌های ارزیابی (MAE, RMSE, R²)**: معیارهای اصلی سنجش عملکرد مدل‌های رگرسیون هستند:
 - MAE** میانگین خطای مطلق: میانگین قدر مطلق اختلاف بین مقادیر واقعی و پیش‌بینی شده.
 - RMSE** ریشه میانگین مربعات خطا: مشابه MAE اما خطاهای بزرگ‌تر را با توان دوم کردن، شدیدتر جریمه می‌کند.

R^2 ضریب تعیین: درصد از تغییرات متغیر وابسته (هدف) که توسط مدل توضیح داده می‌شود (مقادیر نزدیک به ۱ نشان‌دهنده برازش عالی است).

- پیش‌بینی بازگشتی (Recursive Forecasting): روشی برای پیش‌بینی چند گام به جلو در مدل‌های توالی‌محور است. در این روش، خروجی پیش‌بینی شده برای گام جاری، به عنوان ورودی گام بعدی به مدل بازگردانده می‌شود تا پیش‌بینی‌های میان‌مدت (مثلاً ۱۰ روز آینده) تولید گردد.
- تحلیل احساسات (Sentiment Analysis): فرآیند پردازش زبان طبیعی (NLP) برای تشخیص بار عاطفی (مثبت، منفی یا خنثی) یک متن است. در این پروژه، این تحلیل روی اخبار اقتصادی اعمال می‌شود تا امتیازی بین ۱- تا ۱+ به عنوان یکی از ورودی‌های مدل پیش‌بینی تولید شود.